

Devolución académica — Auditoría de Trabajo

Final Integrador

Trabajo evaluado: *Sistema Inteligente de Gestión de Leads: Integración de Orquestación Low-Code, IA Generativa y Desarrollo Web Seguro con Python* **Autores:** Fracapani, Fabricio — Lepez, Martin
Carrera: Tecnicatura Superior en Programación — UTN, Facultad Regional Mendoza **Versión auditada:** v7 (los dos archivos entregados son binariamente idénticos: MD5 61befa0b43f56e1f6feffc7153e81c27 . Entregar un solo archivo) **Fecha de la devolución:** 19 de agosto de 2026

1. Dictamen general

El trabajo se **aprueba con condiciones**: es un TFI de nivel claramente superior a la media para una tecnicatura, con un artefacto real, funcionando y medido de extremo a extremo, y con una honestidad metodológica poco frecuente (declara limitaciones, distingue lo demostrado de lo sugerido, admite que el hash SHA-256 no es anonimización, admite brechas de la Ley 25.326). **No corresponde rechazo ni reescritura de fondo.**

Sin embargo, hay **cuatro inconsistencias internas verificables** entre el diseño experimental declarado (§5.1, Tabla 8) y la evidencia efectivamente presentada (Anexo F), más **tres omisiones sustantivas** (autenticación del dashboard, riesgo de inyección de prompt, corpus de prueba no publicado) que un jurado exigente marcará en la defensa. Todas son subsanables sin volver a ejecutar el sistema, salvo la recomendación R-03 (repetición de corridas), que sí exige nueva ejecución y es la única mejora que elevaría el trabajo de "muy bueno" a "distinguido".

Estimación de esfuerzo de corrección: 12 a 20 horas de trabajo de escritorio + 2 a 3 horas de nueva ejecución si se adopta R-03.

2. Lo que está bien y conviene defender en la exposición oral

No es cortesía: son puntos que el jurado debe ver que ustedes saben que son fuertes.

- 1. La estadística está correcta.** Recaliculé de forma independiente los cinco intervalos de Wilson informados en la Tabla 11 y los cuatro coinciden exactamente con los publicados ([89,5 %; 99,2 %] global, [83,9 %; 100 %], [75,0 %; 97,8 %], [72,2 %; 100 %]). El uso de Wilson en lugar del intervalo normal con n pequeño y proporciones cercanas a 1 es la decisión técnicamente correcta y está bien justificada.
- 2. Las métricas de latencia son reproducibles a partir del Anexo F.** Recaliculando los 91 valores de la Tabla F.1 obtengo media = 3,289 s, $90/91 \leq 8$ s y $86/91 \leq 5$ s: coincide con lo informado.

Que los datos crudos permitan reconstruir los agregados es exactamente lo que un evaluador busca y muchos TFI no ofrecen.

- 3. **Consistencia entre anexos.** Los KPI de la captura del dashboard (Anexo I: 22 compra_inmediata , 35 solicita_info , 19 spam, 91 totales) se derivan exactamente de la Tabla F.1. Los 72 correos generados = 91 – 19 spam también cierran. Esa trazabilidad numérica cruzada es un punto fuerte real.
- 4. **La matriz de confusión cierra por filas y columnas** (65/65) y es coherente con el texto.
- 5. **La declaración de la anomalía del caso CP-06** (un teléfono inválido que se persistió cuando debía rechazarse) es un acto de honestidad académica. **No la escondan en la reescritura: destáquenla.** Reportar un fallo propio vale más que un 100 % impoluto.
- 6. **El Anexo J** (brechas normativas Ley 25.326) es el mejor apartado del trabajo. Convierte una debilidad en aporte.
- 7. **La hipótesis con condiciones de refutación operacionales** y la matriz de trazabilidad objetivo–caso–evidencia son buenas prácticas metodológicas que la mayoría de los TFI de desarrollo omite.

3. Hallazgos críticos (bloquean la aprobación sin corrección)

Criterio: contradicción interna verificable, o afirmación no sostenida por la evidencia presentada.

C-01 — El diseño muestral declarado (§5.1 y Tabla 8) no coincide con la evidencia del Anexo F

Ubicación: §5.1, Tabla 8 (CP-07, CP-09) vs. Tabla F.1 y su nota.

Qué dice §5.1: los 25 casos de robustez son «duplicados (10), caracteres especiales (5), mensajes largos (5) y mensajes de borde (5)».

Qué muestra el Anexo F (recuento fila por fila que realicé sobre las 26 filas de robustez):

Grupo real en Tabla F.1	Casos	Declarado en §5.1
Duplicados (Duplicado 1-5)	5	10
Nombres con caracteres especiales (Maria Jose, Joao, Soren, Francois, Anastasia)	5	5
Adversariales (Prompt Injection, Role Confusion, Mezcla Intención, Falso Positivo, Lenguaje Agresivo)	5	no declarados
Multilingües (German, Italian, English Only, Portuguese, Spanglish)	5	no declarados
Mensajes de borde (Solo Signos, Solo Numeros, Muy Corto, Muy Largo, Html Injection)	5	5 (+5 «largos»)
Caso anómalo Tel (teléfono inválido persistido)	1	—
Total	26	25 + 1 anomalía

La propia nota de la Tabla F.1 menciona casos «adversariales y multilingües» que **no existen en el protocolo de la Tabla 8**. Es una contradicción directa entre el capítulo de diseño y el anexo de evidencia.

Gravedad: alta. Un jurado que cuente las filas —y va a contarlas— concluirá que el protocolo se escribió *después* de la corrida y se ajustó a medias.

Corrección exigida:

- 1. Reescribir §5.1 con la composición **real**: 5 grupos de robustez de 5 casos cada uno (duplicados, caracteres especiales, adversariales, multilingües, borde).
- 2. Ampliar la Tabla 8 a CP-01...CP-12, incorporando CP-11 Adversariales (5) y CP-12 Multilingües (5) , y corregir CP-07 Duplicados de 10 → 5.
- 3. Eliminar la fila «CP-09 Mensajes largos (5)» o fusionarla con «mensajes de borde», ya que en la evidencia hay **un solo** caso de mensaje largo (Muy Largo). Ver C-02.

C-02 — El único evento que incumple el umbral de 8 s es también el único caso largo: la tasa de fallo real de esa condición es 1/1, no 1/91

Ubicación: §5.4.1, Tabla 13 fila (i), Anexo F fila Muy Largo (11,62 s).

El trabajo informa «un único evento superó los 8 segundos» y lo trata como ruido estadístico. Pero cruzando la Tabla F.1 con el diseño, ese evento es Muy Largo , es decir, **el caso de mensaje extenso**. Si en el corpus hay un solo mensaje largo y ese mensaje excede el umbral, la lectura correcta no es «1,1 % de fallos» sino **«el 100 % de los mensajes largos incumplió el requisito de latencia»**, con un valor 3,5 veces superior a la media.

Esto no refuta la hipótesis (la condición (i) exige >9 eventos), pero **sí identifica una relación causal que el trabajo tiene delante y no explota**: la latencia de generación depende de la longitud del mensaje de entrada, porque el costo dominante son las dos llamadas a GPT-4o-mini.

Corrección exigida:

- 1. Nombrar el outlier en §5.4.1 e identificar su causa.
- 2. Agregar en §6.1 o §6.3 el análisis: el umbral de 8 s es robusto para mensajes de longitud típica y **frágil para el percentil superior de longitud**.
- 3. Incorporar la variable «longitud del mensaje (caracteres)» a la Tabla F.1 y una figura de dispersión LRT vs. longitud (n=91). Es una figura de 15 minutos que agrega un hallazgo propio al trabajo.
- 4. Convertirlo en limitación explícita y en línea de trabajo futuro (truncado o *streaming* para entradas largas).

Oportunidad, no solo defecto: este es el hallazgo empírico más interesante que produjeron y está enterrado en una nota al pie. Súbanlo al cuerpo.

C-03 — La media única de LRT mezcla dos rutas de ejecución distintas y subestima la latencia real del caso de uso

Ubicación: §5.4.1, Tabla 7, Tabla 14, Resumen Ejecutivo, Abstract.

Los 19 leads clasificados como spam **no pasan por el nodo de generación de email** (§3.3, Anexo G: el IF «¿Es SPAM?» bifurca directo a persistencia). Por lo tanto recorren un pipeline de una sola llamada a OpenAI. Promediarlos junto con los 72 que hacen dos llamadas produce una media artificialmente baja.

Estratificación que calculé sobre los datos del Anexo F:

Ruta	n	Media	s	Máx.
Con generación de email (ruta completa)	72	3,79 s	1,17 s	11,62 s
Sin generación (clasificado spam)	19	1,38 s	0,61 s	3,05 s
Agregado informado en el TFI	91	3,29 s	1,46 s	11,62 s

La media de 3,29 s que aparece en el Resumen, el Abstract, la Tabla 7 y la Tabla 14 **no corresponde al caso de uso que el sistema promete resolver** (responder al prospecto). Para un lead real que recibe respuesta, la latencia media es 3,79 s.

Corrección exigida: reportar las tres cifras (agregada, ruta completa, ruta spam) en §5.4.1 y usar **3,79 s** —no 3,29 s— en toda afirmación sobre tiempo de respuesta al prospecto (Resumen, Abstract, Tabla 14). La conclusión no cambia (sigue muy por debajo de 8 s), pero la métrica pasa a ser defendible.

Corrección adicional (redondeo): el desvío estándar correcto es **s = 1,46 s** (calculado: 1,4559), no 1,45 s como figura en §5.4.1.

C-04 — La tasa de persistencia del 100 % (91/91) es tautológica tal como está definida

Ubicación: §5.4.3, Tabla 13 fila (ii), Resumen, Abstract, Conclusiones.

El numerador y el denominador son la misma cantidad: se cuentan como «leads procesados» los 91 que efectivamente quedaron en la base. Cualquier evento que se hubiera perdido *antes* de persistir simplemente no aparecería en el denominador. Así definida, la métrica **no puede dar otro valor que 100 %** y por lo tanto no es falsable, lo que contradice el marco popperiano invocado en §1.3.

Corrección exigida: redefinir operacionalmente la tasa de persistencia con un denominador independiente y observable *ex ante*:

$$\text{Tasa de persistencia} = (\text{leads presentes en la tabla } \texttt{leads}) / (\text{eventos aceptados por Flask con HTTP 200 y reenviados al webhook de n8n})$$

y reportar el denominador desde los logs de Flask, no desde Supabase. Si el resultado sigue siendo 91/91, la afirmación queda intacta pero ahora **sí es refutable**. Aclararlo cuesta un párrafo y neutraliza la objeción más filosa que pueden recibir en la defensa.

C-05 — El correo de ejemplo del Anexo H contiene una alucinación factual que el trabajo presenta como evidencia de éxito

Ubicación: Anexo H, ejemplo `solicita_info` (lead «Info 2 Test»).

El correo generado y **efectivamente enviado** afirma: «Adjunto a este correo encontrarás un documento con detalles sobre nuestras ofertas...». El pipeline no adjunta ningún documento: el nodo Gmail envía únicamente el HTML generado. Es una afirmación falsa remitida a un destinatario real.

Del mismo modo, el prompt de sistema instruye «incluye un link genérico de calendario» y simultáneamente «NO uses placeholders»: son instrucciones mutuamente contradictorias, y un enlace de calendario «genérico» inventado por el modelo es precisamente una URL fabricada.

Por qué es crítico: el trabajo presenta los tres correos como prueba de que el sistema funciona («sin edición manual») y en la nota final solo verifica la ausencia de *placeholders*. La alucinación está a la vista y no se detecta. Un jurado que lea con atención lo va a notar, y el efecto sobre la credibilidad del apartado es desproporcionado respecto de la gravedad técnica real.

Corrección exigida:

1. Señalar explícitamente la alucinación en el Anexo H, con una nota del tipo: «*Obsérvese que el correo menciona un documento adjunto inexistente. Este caso constituye evidencia empírica directa de la limitación L7 (riesgo de alucinación) y de la necesidad del control de aprobación humana recomendado en el Anexo J, apartado 5.*»
2. Corregir la contradicción del prompt: eliminar «link genérico de calendario» o reemplazarlo por una variable inyectada desde n8n (`{{ $env.CALENDAR_URL }}`), y agregar la restricción «no afirmes la existencia de adjuntos, enlaces ni documentos que no se te proporcionen».
3. Citarlo en §6.1 y en la limitación L7 de la Tabla 15.

Convertirlo en hallazgo los favorece. Un TFI que detecta una alucinación en su propia salida y la documenta demuestra más criterio que uno que muestra tres correos perfectos.

4. Hallazgos mayores (afectan la calidad de la evaluación)

M-01 — Contradicción numérica sobre el esquema de base de datos

Figura 3 (nota): «11 políticas RLS, 12 índices, 2 vistas y 4 funciones». **§4.4:** «4 tablas, 8 índices, 2 vistas, 3 funciones PL/pgSQL, 1 trigger». **§3.4:** enumera 3 funciones (`auto_hash_lead`, `anonymize_ip`, `verify_api_key`). → Verificar contra `schema.sql` y unificar. Sugerencia: si el trigger se cuenta como función, decirlo explícitamente.

M-02 — No se describe el mecanismo de autenticación del dashboard

El esquema RLS asigna a `authenticated` los permisos SELECT/UPDATE sobre `leads` (§3.4, Anexo J), pero **en ninguna parte del trabajo se explica cómo el dashboard Streamlit obtiene ese rol**: no hay login, ni Supabase Auth, ni gestión de sesión descrita. El Anexo I solo dice «Conexión: Supabase PostgreSQL vía supabase-py». Si el dashboard usa la `anon key` o la `service_role key` embebida, toda la arquitectura RLS queda anulada en la práctica y el trabajo estaría reportando un control que no opera.

Es la brecha más seria del capítulo de seguridad y **no está en el Anexo J**. Agregar §3.5.1 «Autenticación y autorización del dashboard» describiendo el mecanismo real, y si no existe, declararlo como limitación L8 y como trabajo futuro prioritario.

M-03 — Ausencia total de análisis de inyección de prompt

El mensaje libre del prospecto se inyecta **sin sanitización semántica** en el prompt de sistema de dos modelos, y la salida del segundo se envía por correo a un tercero. Es el vector de ataque característico de las aplicaciones LLM. El trabajo:

- incluye un caso de prueba `Adv Prompt Injectio` (que el modelo clasificó como spam),
- pero **no lo menciona en §5.4, ni en §6, ni en el Anexo J**, ni cita OWASP Top 10 for LLM Applications.

Habiendo hecho la prueba, no reportarla es desperdiciar evidencia. Agregar: (a) un apartado en Anexo J sobre riesgos específicos de LLM (inyección de prompt, fuga del prompt de sistema, generación de contenido inapropiado enviado en nombre de la empresa), (b) el resultado del caso adversarial en §5.4.2, (c) referencia a OWASP para LLM.

M-04 — Solo se informa *recall* de spam; la *precisión* es del 52,6 %

El Anexo F destaca «recall de spam 100 %». Pero sobre los 91 leads, la IA marcó como spam 19 casos, de los cuales **solo 10 eran spam por diseño**. Precisión = 10/19 = **52,6 %**. Entre los 9 falsos positivos hay 4 duplicados (que son reenvíos de leads legítimos) y mensajes de borde.

Consecuencia funcional, no estadística: **un prospecto real que reenvía el formulario queda silenciosamente sin respuesta**. El texto de §5.4.3 presenta esto como «comportamiento coherente con el diseño», lo cual es una interpretación benévola de un falso positivo.

Reportar precisión, recall y F1 por clase. Sobre los 65 casos etiquetados calculé: macro-F1 = 0,967; precisión de `soporte` = 0,833 (2 FP); recall de `solicita_info` = 0,920. Informar solo *exactitud global* sobre un conjunto casi balanceado y construido por los propios autores sobreestima el desempeño.

M-05 — Corrida única con temperatura > 0: no hay estimación de variabilidad

§4.6 reconoce con acierto que el sistema no es determinista (T = 0,2 y 0,5), pero luego el trabajo entero descansa sobre **una sola ejecución**. Los intervalos de Wilson capturan el error de muestreo del corpus, **no** la variabilidad del modelo entre corridas: son dos fuentes de incertidumbre distintas y el trabajo trata la segunda como inexistente.

Recomendación R-03 (la única que exige nueva ejecución): repetir la corrida 3 veces sobre los mismos 65 casos etiquetados (costo estimado: ~US\$0,08 y menos de 20 minutos) e informar exactitud media ± desvío entre corridas, más el porcentaje de casos con clasificación estable en las 3. Es la mejora individual de mayor impacto sobre la solidez del trabajo.

M-06 — Errores en la matriz de trazabilidad (Tabla 9)

- **OE3 (IA integrada)** → «CP-01, CP-02, CP-06, CP-08»: CP-06 son teléfonos inválidos que se rechazan en Flask y **nunca llegan a la IA**. No puede ser evidencia de OE3. Debería ser CP-01 a CP-04.
- **OE5 (Persistencia)** → «CP-01 a CP-08»: CP-05 y CP-06 son rechazos en Flask, no se persisten. Debería ser CP-01 a CP-04 (+ CP-07 a CP-10).
- **OE7** → **CF-01 a CF-04**: los casos CF **no están definidos en ninguna parte del §5.2**; aparecen recién en §5.4.3. Agregar una Tabla 8-bis «Protocolo de casos de fallo (CF-01 a CF-04)» en §5.2.
- No existe matriz **RF** → **evidencia**. RF-06 («email recibido en bandeja destino») y RF-07 («mensaje en canal #nuevos-leads») **no tienen ninguna evidencia en los anexos**: no hay captura de bandeja de entrada ni de Slack. Agregarlas o declarar el requisito como no verificado.

M-07 — Los 13 controles de seguridad se verifican por inspección de configuración, no por prueba negativa

El criterio de aceptación de RF-10 es «inspeccionar encabezados HTTP». Eso prueba que el header **está**, no que el control **funciona**. No hay un solo caso de prueba que intente vulnerar el sistema:

Control	Prueba negativa faltante	Resultado esperado
CSRF	POST sin token / con token de otra sesión	403
Rate limiting	61 peticiones en 60 s desde una IP	429
Honeypot	POST con <code>_hp_field</code> completado	descarte silencioso
Input sanitization	payload <code><script></code> / <code></code>	almacenado inocuo
RLS	SELECT sobre <code>leads</code> con <code>anon key</code>	0 filas / error
RLS append-only	DELETE sobre <code>lead_events</code>	denegado

Nota relacionada: existe un caso `Html Injection` en el corpus que fue persistido y clasificado como `soporte`, pero **no se reporta si el HTML fue neutralizado**. Es exactamente la evidencia que falta y ya la tienen en la base: consultar el campo `mensaje` de esa fila y documentarlo.

Añadir un bloque `CS-01...CS-06` (casos de seguridad) en §5.2 y sus resultados en §5.4. Con `curl` son 30 minutos de trabajo y cierra el flanco más débil del capítulo de validación.

M-08 — Ausencia de declaración ética y de procedencia de los datos de prueba

Un trabajo cuyo eje es la protección de datos personales **debe declarar** que los 100 leads son sintéticos, que no se procesaron datos de personas reales y a qué casillas se enviaron los 72 correos (buzones controlados de los autores). Actualmente no se dice en ninguna parte, y el sistema envió correos reales vía Gmail API. Agregar un párrafo en §1.6 o §5.1 y una mención en la Declaración de Autoría.

M-09 — El corpus de prueba no se publica: los resultados no son auditables

El Anexo F informa clasificación esperada y obtenida, pero **no el texto de los mensajes**. Sin ellos, un tercero no puede evaluar si las etiquetas esperadas eran razonables ni reproducir el experimento; y la limitación L6 (circularidad) queda sin mitigación posible. Agregar **Anexo K: Corpus de prueba (100 casos)** con el texto íntegro de cada mensaje y su etiqueta de diseño, o publicarlo en el repositorio con enlace y *hash* de commit.

M-10 — El umbral de 8 segundos no está justificado

Es el eje de la hipótesis, del objetivo general y de RNF-01, y **aparece por primera vez sin fundamentación**. La literatura citada (Oldroyd) habla de 5 minutos, tres órdenes de magnitud por encima. Justificarlo explícitamente: por ejemplo, como umbral de percepción de respuesta cuasi-inmediata en interacción web, o como margen respecto del timeout de la petición HTTP.

Alternativamente, reconocer que es un criterio de ingeniería autoimpuesto, más exigente que el de la literatura — lo cual es una decisión legítima si se declara.

M-11 — Atribución imprecisa del dato «21 veces» (§1.1 y §2.7.1)

Se escribe «Oldroyd et al. (2011) y Oldroyd (2007) documentan que responder en menos de cinco minutos multiplica por 21...». El artículo de HBR de 2011 y el *Lead Response Management Study* reportan cifras y diseños distintos; el factor $21\times$ a 5 vs. 30 minutos proviene del segundo, que es literatura de industria patrocinada por un proveedor (InsideSales.com), **no** evidencia académica revisada por pares. Atribuir el mismo dato a ambas fuentes debilita la sección.

Corrección: atribuir el $21\times$ exclusivamente a Oldroyd (2007), etiquetarlo como [Industria] (ya lo hacen en §2.7.1, pero no en §1.1), y advertir del posible conflicto de interés de la fuente. Ustedes ya hacen esta clase de advertencia con acierto en §6.2 respecto del canal telefónico: extiéndanla.

M-12 — La columna «Manual» de la Tabla 14 presenta cifras sin respaldo

«4-8h», «12-24h», «~70 % de registros completos» aparecen como datos junto a mediciones propias. La nota admite que son «valores de referencia cualitativos», pero ni Chaffey & Ellis-Chadwick ni HubSpot proveen esas cifras específicas. Opciones: (a) citar página exacta, (b) reemplazar por descripciones cualitativas sin números, (c) declararlas como estimación propia razonada. Tal como está, la tabla induce a leer como comparación empírica lo que es una ilustración.

M-13 — Anexos A a E son descripciones, no anexos

«Fragmento de `app.py` con los 13 controles...» es un resumen del anexo, no el anexo. Un TFI de desarrollo debe incluir el código de los artefactos verificados o, como mínimo, el enlace al repositorio **con el hash de commit exacto** de la versión validada el 18/08/2026. Sin eso, el repositorio puede cambiar y la evidencia se vuelve irreproducible.

M-14 — Desfase temporal en la datación de la evidencia

Los Anexos G e I llevan «Documento generado: 2026-08-05 19:42:33 UTC», **13 días antes** de la corrida que dicen documentar (18/08/2026, `test_100_v3`). Además, el Anexo G identifica el workflow como «TFI UTN FRM v6 / Versión: 6.0.0» mientras el documento es v7. Regenerar los anexos con posterioridad a la corrida y unificar versionado. Una evidencia fechada antes del hecho que prueba es un problema de forma que se lee como un problema de fondo.

M-15 — El *fallback* de CF-04 contamina los datos y contradice el principio *fail-loudly*

Ante fallo de la API de OpenAI, el pipeline asigna `clasificacion = solicita_info, prioridad = 50, confianza = 0,5` y persiste. El registro queda **indistinguible** de una clasificación genuina en el dashboard y en cualquier análisis posterior. Es lo contrario de *fail-loudly*: falla ruidosamente en Slack y silenciosamente en la base.

Recomendación: valor centinela `sin_clasificar` con `confianza = NULL` y un flag `ia_fallback = true`, más su reflejo en el KPI del dashboard. Documentarlo como corrección pendiente aunque no se implemente.

5. Hallazgos menores

ID	Ubicación	Problema	Corrección
m-01	Cap. 7	Existe «7.2 Aportes» pero falta el encabezado «7.1 Conclusiones Generales» que el índice anuncia	Agregar el encabezado 7.1
m-02	§5.4 / Índice	«Verificación de Hipótesis» y «Comparativa Manual vs Automatizado» no están numeradas	Numerar como 5.4.4 y 5.4.5 y actualizar el índice
m-03	Índice general	«Índice de Tablas / Figuras / Acrónimos: (Ver sección correspondiente al final de este índice)» y «Lista de Acrónimos» duplicada	Reemplazar por número de página real; eliminar la entrada duplicada
m-04	Índice de Tablas	Tabla 7: el índice dice «Métricas de ejecución y recursos del pipeline», el cuerpo «...con 100 casos de prueba»	Unificar título
m-05	Tabla 7	Fila «Ejecuciones/mes (plan Cloud)» con valor «Autoalojado (Docker): sin límite» y método «n8n Cloud dashboard»: los tres campos se contradicen	Renombrar la fila «Límite de ejecuciones» y corregir el método
m-06	§5.4.3, KPI dashboard	La IA asigna prioridad 50 a los spam , que entra en el KPI «prioridad promedio» (62) y lo distorsiona	Forzar <code>prioridad = 0</code> para spam en post-procesamiento, o excluir spam del KPI
m-07	Anexo H	El JSON del prompt usa comilla tipográfica (<code>"prioridad":</code>) y clave acentuada <code>"clasificación"</code> , mientras la BD usa <code>ia_clasificacion</code>	Normalizar a ASCII sin acentos y usar <i>structured outputs</i> / <code>response_format: json_schema</code>

ID	Ubicación	Problema	Corrección
m-08	§5.4.1	Solo se informa la media; falta mediana, p90, p95, mín. y máx.	Datos ya calculables del Anexo F: mediana 3,37 s; p90 4,29 s; p95 5,03 s; mín. 0,91 s; máx. 11,62 s. Agregar tabla e histograma
m-09	§5.2, CP-07	Un caso de prueba cuyo «resultado esperado» es una limitación no implementada no es una prueba	Reencuadrar como observación de robustez, o definir criterio verificable
m-10	§1.2.1	El objetivo general incorpora el resultado («reduciendo el LRT por debajo de 8 s»)	Reformular como criterio de diseño: «...con el objetivo de mantener el LRT por debajo de 8 s»
m-11	§1.3 / §6.1	El marco popperiano se aplica a una afirmación de viabilidad de un artefacto propio, que no es una hipótesis universal falsable	Matizar en §6.1: se adoptan <i>criterios de refutación operacionales</i> inspirados en Popper como disciplina de validación, sin pretender contrastación de una ley general
m-12	§5.1, OE8	Se declaran 100 casos, pero se ejecutaron 104 eventos (100 + CF-01... CF-04)	Declarar «100 casos funcionales + 4 casos de inyección de fallos»
m-13	Referencias	Falta la fuente del método de Wilson, pese a ser la base de todos los IC	Agregar Wilson, E. B. (1927). <i>JASA</i> , 22(158), 209–212
m-14	Referencias	Se citan RFC 5322, RFC 4122 (UUID v4) e ISO 8601 sin referenciarlos	Incorporar a la lista
m-15	§2.1	La categoría PQL se atribuye a Kotler & Keller (2016) y Chaffey & Ellis-Chadwick (2019); PQL es un constructo posterior del ámbito SaaS	Atribuir a fuente adecuada o marcar como [Industria]
m-16	Lista de Acrónimos	XSS y UML figuran pero no se usan en el cuerpo	Eliminarlos o usarlos
m-17	Resumen	~300 palabras; la convención habitual es ≤250	Comprimir
m-18	Abstract	Omite la salvedad sobre entorno controlado que sí trae el resumen en español	Añadir la frase equivalente
m-19	§4.1, §4.6	«Flask 3.x», «n8n 1.x», «Streamlit 1.x»: versiones sin fijar, justo en el apartado que argumenta reproducibilidad	Fijar versiones exactas y adjuntar <code>requirements.txt</code> + <code>docker-compose.yml</code>
m-20	§4.6	Se recomienda fijar el <i>snapshot</i> del modelo, pero no se declara cuál se usó en la corrida	Indicar el identificador exacto (p. ej. <code>gpt-4o-mini-2024-07-18</code>)
m-21	Portada / Declaración	Sin director/tutor, sin fecha de presentación, sin lugar para firma	Agregar según reglamento de la FRM
m-22	§2.6, Anexo J	Se cita solo la Ley 25.326	Verificar y citar la normativa reglamentaria vigente de la AAIP sobre medidas de seguridad, y mencionar el estado de los proyectos de reforma
m-23	§5.4.3	El rate limiting (60 req/min/IP) nunca se activó con 100 envíos secuenciales desde una IP	Declarar la cadencia del script de prueba para evitar la sospecha de que el control estuvo desactivado
m-24	Anexo J, punto 5	Reconoce el riesgo de alucinación pero no lo vincula al ejemplo concreto del Anexo H	Enlazar con C-05

6. Corrección editorial y de estilo

6.1 Erratas a corregir (lista textual)

Ubicación	Dice	Debe decir
§4.1 (título)	«Stack Tecnológico»	«Stack Tecnológico»
§2.1	«PQL (...experimento el producto)»	«...experimenta con el producto»
§4.2	«13 controles vía @app. after_request»	«@app.after_request» (sin espacio)
§4.3	«Gmail (envió)», «validacion email»	«envío», «validación de email»
Anexo G	«Slack (nota. equipo)»	«Slack (notificación al equipo)»
Anexo G	«Normalizacion», «Validacion», «telefono», «Clasificacion IA»	acentuar
Anexo J, punto 5	«se envía directamente al leadsin revisión humana»	«al lead sin revisión humana»
§5.4.3	«la llamada a GPT4o-mini»	«GPT-4o-mini»
Tabla 2	«Auto Alojamiento — Si»	«Sí»
Tabla 6	«\$0 (500/dia)»	«(500/día)»
§3.2	«Contador de caracteres» (mayúscula intercalada)	minúscula
Anexo H	«Responde ÚNICAMENTE con JSON valido»	«válido»
§2.6	«credencial store cifrado»	«almacén de credenciales cifrado»

6.2 Uniformidad numérica (afecta todo el documento)

Conviven las dos convenciones decimales: «2,12 segundos» / «3.3s»; «~US\$0,0004» (Tabla 5) / «~US\$0.0004» (Resumen, Tabla 6, Cap. 7). En un texto en español debe usarse **coma decimal en todo el documento**, incluidos importes y tablas. Igualmente, unificar el espacio antes del signo de porcentaje («96,9 %» vs. «92,0%») y usar semirraya en rangos («20–30 %», «75–85 %»).

6.3 Cumplimiento de APA 7 (ítems que un jurado formalista marcará)

1. **Etiquetas** [Académica] / [Industria] / [Técnica] **en la lista de referencias.** La intención — transparencia sobre el tipo de fuente— es excelente y hay que conservarla, pero **rompe el orden alfabético**, que APA exige. Solución: lista de referencias en APA estricto (alfabética, sin corchetes) + una **tabla de clasificación de fuentes** en el marco teórico o como Anexo. Se conserva el aporte y se cumple la norma.
2. **Orden alfabético.** Actualmente Popper aparece antes que Oldroyd, y todo el bloque de LLM (Brown, Kojima, Wei, Zhao, Minaee, Yang) está apilado al final. Reordenar.
3. **Conectores de autoría.** Coexisten «&» (Chaffey & Ellis-Chadwick; Kotler & Keller) y «y» (Dumas... y Reijers). En APA en español corresponde «y» en todas las entradas y citas.
4. **Nombre de autor institucional.** El texto cita «HubSpot (2025)» y «OWASP Top 10 (2021)»; las referencias dicen «HubSpot Research» y «OWASP Foundation». Unificar cita y entrada.
5. **Títulos de tablas.** APA 7: número en línea propia, y debajo el título en cursiva. El documento pone «Tabla 1 Tipología de leads...» en una sola línea. Corregir en las 17 tablas.
6. **Notas de tabla.** «Nota. Fuente: elaboración propia» no es APA; corresponde «*Nota. Elaboración propia.*»
7. **Figuras.** En APA 7 el número y el título van **encima** de la imagen y la nota debajo; el documento coloca el rótulo debajo en las Figuras 1–3. Además, las Figuras G.1 e I.1 no aparecen en el Índice de Figuras.

8. **Legibilidad de la Figura 1.** El diagrama de arquitectura es ilegible al tamaño impreso. Rehacerlo en orientación apaisada, en página completa, o dividirlo en dos figuras (flujo de datos / componentes).
9. **Fuentes no recuperables.** «<https://www.gartner.com>» y «<https://www.forrester.com>» son dominios raíz, no localizadores de la obra citada. Aportar URL específica o indicar que el informe es de acceso restringido.

7. Plan de corrección priorizado

Bloque 1 — Imprescindible antes de reenviar (≈6 h)

- 1. C-01: reescribir §5.1 y Tabla 8 con la composición real del corpus.
- 2. C-04: redefinir la tasa de persistencia con denominador independiente.
- 3. C-03: estratificar el LRT y corregir 3,29 → 3,79 s en toda afirmación sobre respuesta al prospecto; s = 1,46.
- 4. C-05: anotar la alucinación del Anexo H y corregir el prompt.
- 5. M-01, M-06: resolver contradicciones de esquema y arreglar la matriz de trazabilidad.
- 6. m-01 a m-05: numeración de secciones e índices.

Bloque 2 — Eleva sustancialmente la calificación (≈8 h) 7. C-02: análisis del outlier y figura LRT vs. longitud del mensaje. 8. M-04: precisión/recall/F1 por clase y discusión del 52,6 % de precisión en spam. 9. M-02: apartado sobre autenticación del dashboard. 10. M-03: riesgos específicos de LLM en el Anexo J. 11. M-07: bloque de pruebas negativas de seguridad (CS-01...CS-06). 12. M-08, M-09: declaración ética + Anexo K con el corpus.

Bloque 3 — Distingue el trabajo (≈3 h + nueva corrida) 13. M-05 / R-03: tres corridas y reporte de estabilidad entre ejecuciones. 14. M-13, M-14: anexos con código real, hash de commit, regeneración fechada. 15. Bloque editorial completo (§6).

8. Rúbrica de evaluación

Dimensión	Peso	Estado actual	Tras Bloques 1–2
Planteo del problema y pregunta de investigación	10 %	8,5	9,0
Marco teórico y estado del arte	15 %	8,0	8,5
Diseño de la solución y arquitectura	15 %	9,0	9,0
Implementación y calidad del artefacto	15 %	8,5	8,5
Diseño de validación y rigor metodológico	20 %	6,0	8,5
Análisis y discusión de resultados	10 %	7,0	8,5
Seguridad y cumplimiento normativo	10 %	7,5	9,0
Presentación formal, APA y anexos	5 %	5,5	8,0
Ponderado		7,6	8,7

La dimensión que arrastra la nota es **rigor metodológico**, y no por falta de trabajo empírico —que sobra— sino por desalineación entre lo declarado y lo evidenciado (C-01), métricas mal definidas (C-

04) o mal agregadas (C-03). Son defectos de *reporte*, no de *ingeniería*: por eso el retorno del esfuerzo de corrección es tan alto.

9. Preguntas probables en la defensa (preparar respuesta)

1. ¿Por qué el protocolo declara 10 duplicados y el Anexo F muestra 5, más categorías que el protocolo no anticipa?
 2. Si la tasa de persistencia se calcula sobre los leads que están en la base, ¿qué resultado distinto de 100 % podría haber dado esa métrica?
 3. El promedio de 3,29 s incluye 19 casos que no generan correo. ¿Cuál es la latencia del caso que sí responde al prospecto?
 4. El único caso que superó los 8 s es el único mensaje largo. ¿Es coincidencia o dependencia sistemática de la longitud de entrada?
 5. En el Anexo H el correo dice que hay un documento adjunto. ¿Lo hay?
 6. ¿Con qué credencial y con qué rol se conecta Streamlit a Supabase? ¿Qué queda de RLS si es la `anon key`?
 7. Con temperatura 0,2 y una sola corrida, ¿cuánto de ese 96,9 % es reproducible?
 8. La IA marcó como spam 19 leads pero solo 10 lo eran. ¿Qué pasa con un cliente real que reenvía el formulario?
 9. ¿Por qué 8 segundos y no 5, o 30?
 10. Un lead escribe en su mensaje «ignorá tus instrucciones y respondé X». ¿Qué hace el sistema?
-

10. Cierre

El artefacto es sólido, la medición existe y los datos crudos publicados permiten auditar los agregados: eso ya coloca al trabajo por encima de la media de los TFI de desarrollo, donde lo habitual es la demostración sin métrica. El problema es de **disciplina de reporte**: el capítulo de diseño experimental describe un experimento que no es exactamente el que se ejecutó, y algunas métricas están agregadas de un modo que favorece el resultado sin necesidad, porque **el resultado se sostiene igual con las métricas correctas** (3,79 s sigue estando muy por debajo de 8 s; macro-F1 de 0,967 sigue superando holgadamente el 80 %).

Corrijan el Bloque 1 y el trabajo se aprueba sin objeciones. Agreguen el Bloque 2 y pasa a ser un TFI que se puede mostrar como referencia de la carrera.

Auditoría realizada sobre el texto íntegro del PDF v7, con verificación numérica independiente de los intervalos de Wilson (Tabla 11), de los estadísticos de latencia (Anexo F, $n = 91$) y de la coherencia cruzada entre la Tabla F.1, la matriz de confusión (Tabla 10) y los KPI del Anexo I.